

Modèle de donnée NoSQL

Stripe collecte un certain nombre de données non structurées, qui ne peuvent pas trouver leur place dans des bases relationnelles comme OLTP ou OLAP. Cela concerne, par exemple l'interaction des utilisateurs avec le site, les rapports d'erreur, les données servant à l'entraînement du modèle de machine learning et les feedbacks des utilisateurs. Nous avons donc créé une base de données NoSQL pour les enregistrer. Cette base de données nécessite certaines stratégies afin d'optimiser sa vitesse ainsi qu'une intégration avec les bases de données OLTP et OLAP.

1. Stratégie pour manager les relations entre documents

La première stratégie est de créer un Embedding pour les données qui ne sont pas susceptibles de changer. C'est pour cette raison qu'il a été fait sur les données correspondant à l'interaction de l'utilisateur avec l'application. Chaque clic et navigation de l'utilisateur a donc été directement intégré dans le document. Cela permet une lecture rapide, car toutes les données concernant ce comportement sont au même endroit.

La seconde stratégie consiste à faire du referencing, c'est-à-dire que les documents ont un lien avec des données qui existent déjà. Cela a été fait sur l'ensemble des identifiants, comme `customer_id`, `transaction_id` et `merchant_id`. Cela permet de conserver une cohérence entre les données, et facilite les mises à jour.

Enfin, l'indexing a été appliqué afin de retrouver rapidement certaines informations. C'est pourquoi il faut utiliser cette technique sur les informations qui sont régulièrement recherchées. Il a donc été fait sur les erreurs, notamment sur les identifiants de transaction avec `transaction.transaction_id` ou `transaction.customer_id`. Cela permet de retrouver rapidement une erreur plutôt que de faire parcourir au logiciel toutes les lignes de la base de données pour retrouver les erreurs concernant un commerçant ou un utilisateur.

2. Intégration du NoSQL avec les systèmes OLTP et OLAP

Cette organisation NoSQL vient s'intégrer avec les architectures de type OLTP et OLAP de différentes façons.

Premièrement, la présence des identifiants évoqués ci-dessus permet de faire les liens avec l'architecture OLTP et le NoSQL. Par exemple, quand une transaction a lieu dans le système OLTP, le `transaction_id` est reçu dans le système NoSQL. Ce même identifiant est ensuite stocké dans MongoDB.

Ensuite, le système NoSQL alimente l'architecture avec OLAP avec certaines informations. C'est le cas pour la détection de fraude, qui a besoin des prédictions du modèle de machine learning qui est alimenté par le document NoSQL. Ces inputs permettent de faire une prédiction de score de fraude qui enrichit la base de données OLAP.

Pour fonctionner, le système est orchestré par deux logiciels, Kafka et Apache Airflow. Kafka concerne le streaming en temps réel des données. Il permet de recueillir un événement dans la

base de données OLTP, et de distribuer les informations aux systèmes OLAP et NoSQL. Airflow lui agit comme un orchestrateur, qui va régulièrement extraire des données du système OLTP vers le système OLAP, et synchroniser les données NoSQL vers l'OLAP. Les deux fonctionnent ensemble pour permettre la transition de tous les types de données.

Le système NoSQL présenté a donc trois méthodes permettant d'optimiser la puissance de calcul de la base de données NoSQL. L'embedding permet de retrouver rapidement certaines informations qui ne sont pas susceptibles d'être modifiées dans le temps. Le referencing permet de conserver une cohérence entre les bases de données et facilite les mises à jour. Enfin, l'indexing permet de manipuler rapidement certaines données. Le système peut ainsi gagner en rapidité, avec une meilleure gestion de ses ressources. Aussi, il est pensé pour fonctionner de concert avec les autres types d'architecture OLTP et OLAP.