

Stratégie d'intégration de l'apprentissage automatique

Le machine learning est au cœur de la stratégie de Stripe en ce qui concerne la détection de fraude et la personnalisation de l'expérience client. Ce document décrit le processus d'intégration des modèles de machine learning, de l'extraction des features jusqu'au monitoring en production.

1. Extraction des features

Les features sont les données d'entrée du modèle, elles sont stockées dans `machine_learning_features` de la base de données NoSQL. Elles sont extraites en temps réel de trois sources. La première la base de données OLTP avec le montant, les devises, la localisation, le type d'appareil et l'historique du client. La deuxième vient de la base OLAP avec l'historique analytique du client, et le taux de fraude moyen par pays. Les dernières proviennent de la base de données NoSQL avec le comportement de l'utilisateur. Fafka permet la transmission des données de transaction en temps réel vers MongoDB pour alimenter ces features. Elles sont normalisées et nettoyées avant d'être envoyées au modèle. Chaque document `machine_learning_feature` est enrichi avec des features calculées. Cela concerne le nombre de transactions du client ces dernières vingt-quatre heures, le montant habituel de ses dépenses, le pays habituel où il se trouve et l'utilisation d'un nouvel appareil.

2. Déploiement des modèles

Les modèles sont entraînés séparément sur les données historiques de l'OLAP comme `fact_fraud` et `fact_transaction` qui permettent d'avoir les données cibles pour confirmer par exemple une fraude. Une fois entraîné, le modèle est déployé en production via une API. Stripe peut ainsi l'appeler en temps réel à chaque transaction par l'intermédiaire d'un score de fraude qui constitue la prédiction du modèle. Plusieurs versions du modèle peuvent coexister afin de tester leur performance. Ils sont tous versionnés dans Mlflow, elles sont donc traçables et reproductibles. En cas de problème, un rollback vers les versions précédentes et donc possible en peu de temps.

3. Détection de fraude en temps réel

La détection de fraude est le cas d'usage principal des modèles chez Stripe. Il est nécessaire que le modèle puisse prédire son score de fraude avec la même rapidité que la transaction elle-même, afin de ne pas la ralentir. Les features les plus importantes pour le modèle sont la détection d'un montant inhabituel, d'un nouveau pays, de plusieurs transactions en même temps ou d'une adresse IP suspecte. Et en cas de fraude détectée, une alerte est envoyée via Kafka dans le topic `fraud_alerts`. Les résultats sont ensuite stockés dans `fact_fraud` de l'OLAP pour enrichir les futurs entraînements.

4. Personnalisation client

Un second modèle analyse le comportement des clients afin de personnaliser leur expérience. Les données d'entrée viennent des `user_interactions` dans MongoDB. Elles concernent les pages

visitées, les durées de sessions, les boutons sur lesquels le client a cliqué et l'historique des transactions. Le modèle peut prédire les moyens de paiement proposés en premier et les offres commerciales à afficher. Ces prédictions sont stockées dans MongoDB et utilisées en temps réel pour l'application Stripe.

5. Analyse prédictive

Un troisième modèle prédit les tendances futures à partir des données historiques de l'OLAP. Il permet d'anticiper quel vendeur va quitter la plateforme Stripe et les pics de trafic. Ces modèles tournent en batch chaque nuit via Airflow, ils n'ont pas besoin de prédire en temps réel. Les résultats viennent enrichir les dimensions de l'OLAP comme dim_merchant et dim_customer.

6. Monitoring et mise à jour des modèles

Les performances du modèle sont surveillées en permanence via des métriques. L'accuracy permet de voir combien de détection de fraude était justes. Le Recall permet de voir combien de fraudes ont été détectées parmi toutes celles qui ont eu lieu. Le F1 score montre l'équilibre entre l'accuracy et le Recall et la latence montre le temps de prédiction du modèle. Ces métriques sont stockées dans MongoDB et peuvent être visualisées dans un dashboard. Une alerte est envoyée si les performances tombent en dessous d'un seuil défini.

Le monitoring vise également à détecter les dérives du modèle. Elles peuvent avoir lieu à cause de deux raisons différentes : Le data drift a lieu quand la distribution des données d'entrée change, par exemple par l'émergence d'un nouvel appareil pour se connecter à la plateforme. Le concept drift peut lui avoir lieu lorsque la relation entre les features et les fraudes change, par exemple avec l'apparition d'une nouvelle technique de fraude.

Pour empêcher la dérive des modèles, ceux-ci sont régulièrement entraînés sur de nouvelles données. En ce qui concerne la périodicité de ces entraînements, Stripe dispose d'assez de données pour réentraîner les modèles tous les mois. Aussi, un réentraînement doit être automatiquement déclenché si un drift est détecté. Les nouveaux modèles sont d'abord testés avant d'être déployés en production. Si les nouveaux modèles sont moins performants en condition réelle, un rollback s'effectue automatiquement.

Ainsi, trois modèles coexistent. Ils concernent la détection de fraude, la personnalisation de l'expérience client et l'analyse prédictive. L'extraction des features depuis les trois systèmes garantit des prédictions riches et précises. Le monitoring continu permet d'assurer la fiabilité du modèle et les réentraînements réguliers permettent de s'adapter aux nouvelles techniques de fraude.